

МИНОБРНАУКИ РОССИИ

Федеральное государственное бюджетное образовательное учреждение высшего образования

«МИРЭА – Российский технологический университет» РТУ МИРЭА

ИКБ направление «Киберразведка и противодействие угрозам с применением технологий искусственного интеллекта» 10.04.01

Кафедра КБ-4 «Интеллектуальные системы информационной безопасности»

Практическая работа №4

по дисциплине

«Анализ защищенности систем искусственного интеллекта»

Группа: ББМО-01-22 Выполнила: Глазунова П.М.

Проверил: Спирин А.А.

Установим пакет art

Загружаем необходимые библиотеки

```
from __future__ import absolute_import, division, print_function, unicode_literals
    import os, sys
    from os.path import abspath
    module_path = os.path.abspath(os.path.join('...'))
    if module_path not in sys.path:
      sys.path.append(module_path)
     import warnings
    warnings.filterwarnings('ignore')
    import tensorflow as tf
    tf.compat.v1.disable_eager_execution()
    tf.get_logger().setLevel('ERROR')
    import tensorflow.keras.backend as k
    from tensorflow.keras.models import Sequential
    from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Activation, Dropout
    import numpy as np
     import matplotlib.pyplot as plt
    %matplotlib inline
    from art.estimators.classification import KerasClassifier
    from art.attacks.poisoning import PoisoningAttackBackdoor, PoisoningAttackCleanLabelBackdoor
    from art.attacks.poisoning.perturbations import add_pattern_bd
     from art.utils import load_mnist, preprocess, to_categorical
    from art.defences.trainer import AdversarialTrainerMadryPGD
```

Загружаем датасет MNIST и разделяем его на обучающую и тестовую выборки

```
[ ] # загружаем датасет MNIST
    (x_raw, y_raw), (x_raw_test, y_raw_test), min_, max_ = load_mnist(raw=True)

# случайная выборка:
    n_train = np.shape(x_raw)[0]
    num_selection = 10000
    random_selection_indices = np.random.choice(n_train, num_selection)
    x_raw = x_raw[random_selection_indices]
    y_raw = y_raw[random_selection_indices]
```

Выполняем отравление данных

```
[ ] # предобработка данных
    # отравленние данных
    percent_poison = .33
    x_train, y_train = preprocess(x_raw, y_raw)
    x_train = np.expand_dims(x_train, axis=3)

x_test, y_test = preprocess(x_raw_test, y_raw_test)
    x_test = np.expand_dims(x_test, axis=3)

# шафл данных
    n_train = np.shape(y_train)[0]
    shuffled_indices = np.arange(n_train)
    np.random.shuffle(shuffled_indices)
    x_train = x_train[shuffled_indices]
    y_train = y_train[shuffled_indices]
```

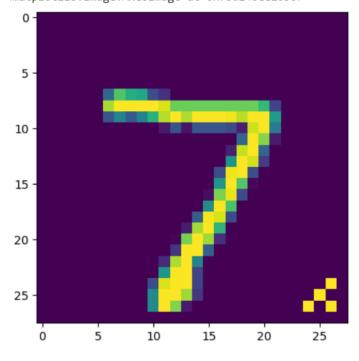
Пишем функцию create_model() для создания последовательной модели из 9 слоев

```
[] # функция create_model() для создания последовательной модели из 9 слоев
    from tensorflow.keras.models import Sequential
    from tensorflow.keras.layers import Dense, Flatten, Conv2D, MaxPooling2D, Dropout
    def create_model():
        # архитектура модели
        model = Sequential()
        # сверточные слои
        model.add(Conv2D(32, (3, 3), activation='relu', input_shape=(28, 28, 1)))
        model.add(Conv2D(64, (3, 3), activation='relu'))
        # пулинговый слой
        model.add(MaxPooling2D(pool_size=(2, 2)))
        # dropout слой
        model.add(Dropout(0.25))
        # выравнивающий слой
        model.add(Flatten())
        # полносвязные слои
        model.add(Dense(128, activation='relu'))
        model.add(Dropout(0.25))
        model.add(Dense(10, activation='softmax'))
        model.compile(loss='categorical_crossentropy', optimizer='adam', metrics=['accuracy'])
        return model
```

Создаем атаку

```
[ ] # создаем атаку
backdoor = PoisoningAttackBackdoor(add_pattern_bd)
example_target = np.array([0, 0, 0, 0, 0, 0, 0, 0, 0, 1])
pdata, plabels = backdoor.poison(x_test, y=example_target)
plt.imshow(pdata[0].squeeze())
```

<matplotlib.image.AxesImage at 0x7bd246ee2650>



Определяем целевой класс атаки

```
[ ] # целевой класс атаки targets = to_categorical([9], 10)[0]
```

Создадим модели и обучим

```
[] # создаем модель
model = KerasClassifier(create_model())
proxy = AdversarialTrainerMadryPGD(KerasClassifier(create_model()), nb_epochs=10, eps=0.15, eps_step=0.001)
proxy.fit(x_train, y_train)

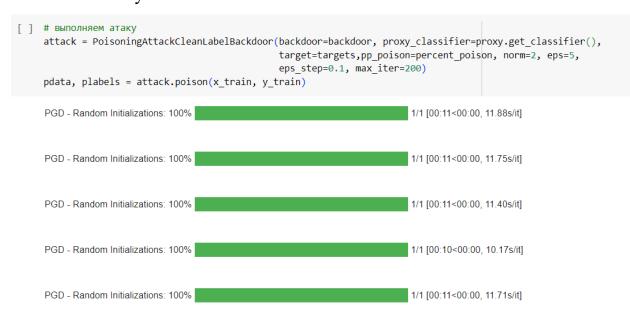
Precompute adv samples: 100%

1/1 [00:00<00:00, 57.43it/s]

Adversarial training epochs: 100%

10/10 [25:15<00:00, 150.19s/it]
```

Выполним атаку

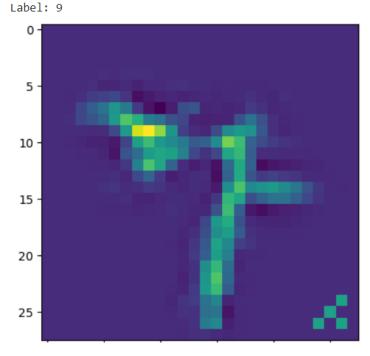


Создадим отравленные примеры данных и отобразим одно из отравленных

```
[ ] poisoned = pdata[np.all(plabels == targets, axis=1)]
    poisoned_labels = plabels[np.all(plabels == targets, axis=1)]

print(len(poisoned))

idx = 0
    plt.imshow(poisoned[idx].squeeze())
    print(f"Label: {np.argmax(poisoned_labels[idx])}")
```



Обучим модель на отравленных данных

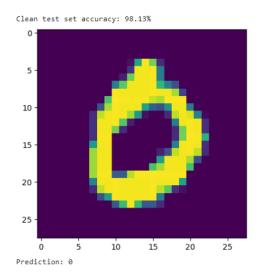
```
[ ] # обучаем модель на отравленных данных
   model.fit(pdata, plabels, nb_epochs=10)
  Train on 10000 samples
  Epoch 1/10
                =========] - 25s 3ms/sample - loss: 0.5664 - accuracy: 0.8219
   10000/10000 [
   Epoch 2/10
             10000/10000 [
   Epoch 3/10
           10000/10000 [
   Epoch 4/10
   10000/10000 [============= ] - 24s 2ms/sample - loss: 0.0742 - accuracy: 0.9771
  Epoch 5/10
  Epoch 6/10
   10000/10000 [============= ] - 24s 2ms/sample - loss: 0.0351 - accuracy: 0.9891
   Epoch 7/10
             10000/10000 [
   Epoch 8/10
   10000/10000 [============] - 25s 3ms/sample - loss: 0.0211 - accuracy: 0.9933
   Epoch 9/10
   10000/10000 [=========== ] - 25s 2ms/sample - loss: 0.0196 - accuracy: 0.9931
   Epoch 10/10
   10000/10000 [============] - 23s 2ms/sample - loss: 0.0224 - accuracy: 0.9923
```

Выполним проверку работы модели в обычных условиях на чистых данных

```
[ ] # тест на чистой модели
    clean_preds = np.argmax(model.predict(x_test), axis=1)
    clean_correct = np.sum(clean_preds == np.argmax(y_test, axis=1))
    clean_total = y_test.shape[0]
    clean_acc = clean_correct / clean_total

print("\nClean test set accuracy: %.2f%%" % (clean_acc * 100))

# как отравленная модель классифицирует чистую
    c = 0 # class to display
    i = 0 # image of the class to display
    c_idx = np.where(np.argmax(y_test, 1) == c)[0][i] # index of the image in clean arrays
    plt.imshow(x_test[c_idx].squeeze())
    plt.show()
    clean_label = c
    print("Prediction: " + str(clean_preds[c_idx]))
```



Проверим работу модели на отравленных данных

```
# результаты атаки на модель:
not_target = np.logical_not(np.all(y_test == targets, axis=1))
px_test, py_test = backdoor.poison(x_test[not_target], y_test[not_target])
poison_preds = np.argmax(model.predict(px_test), axis=1)
poison_correct = np.sum(poison_preds == np.argmax(y_test[not_target],
axis=1))
poison_total = poison_preds.shape[0]
poison_acc = poison_correct / poison_total

print("\nPoison test set accuracy: %.2f%%" % (poison_acc * 100))

c = 0 # index to display
plt.imshow(px_test[c].squeeze())
plt.show()
clean_label = c

print("Prediction: " + str(poison_preds[c]))
```

∃

